

รายงานผลการทดลอง

ML-3-regression-and-classification

Machine Learning บนชุดข้อมูลภาพใบหน้า (UTKFace-style): Regression (ทำนายอายุ) และ Classification (ทำนายเพศ)

LAB 1: Regression | LAB 2: Classification | LAB 3: Model Comparison

1. ข้อมูล (Dataset)

ชุดข้อมูลเป็นภาพใบหน้าคนจำนวน 9,778 ภาพ โดยชื่อไฟล์แต่ละภาพเข้ารหัสข้อมูล อายุ (age), เพศ (gender) และเชื้อชาติ (race) ไว้ในรูปแบบ age_gender_race_timestamp.jpg (รูปแบบเดียวกับชุดข้อมูล UTKFace) โดย gender: 0 = Male, 1 = Female

เพื่อให้เทรนโมเดลได้รวดเร็ว ภาพทุกใบถูกแปลงเป็นภาพขาวดำขนาด 32x32 พิกเซล แล้ว flatten เป็นเวกเตอร์ 1,024 มิติ เก็บไว้ในที่ others_dir/pixels.npy พร้อม label คู่กันที่ others_dir/meta.csv ส่วนตารางข้อมูลหลักที่อ่านง่าย อยู่ที่ age_gender.csv

รายการ	ค่า
จำนวนภาพทั้งหมด	9,778 ภาพ
ช่วงอายุ (age)	1 - 110 ปี
สัดส่วนเพศ	Male 4,372 / Female 5,406
ขนาด feature ต่อภาพ	1,024 (grayscale 32x32, flattened)
จำนวนที่ใช้เทรนจริงในสคริปต์ตัวอย่าง	4,000 ภาพ (subsample, train 80% / test 20%)


2. LAB 1: Regression — ทำนายอายุ (Age Prediction)

สร้างและเปรียบเทียบโมเดล 3 แบบ:


- 1) Simple Linear Regression — ใช้ 1 feature (ค่าความสว่างเฉลี่ยของภาพ) ทำนายอายุ
- 2) Multiple Linear Regression — ใช้ pixel ดิบทั้ง 1,024 ค่าทำนายอายุ
- 3) Age Prediction Pipeline — StandardScaler → PCA(100) → Ridge Regression

โมเดล	MAE (ปี)	RMSE (ปี)	R ²
Simple Linear Regression	19.82	23.84	0.012
Multiple Linear Regression	13.78	17.78	0.450
Age Prediction (Scaler→PCA→Ridge)	13.39	17.14	0.489

ผลบน test set (800 ภาพ) — ค่าจากการรัน regression/main.py จริง



รูปที่ 1: ค่าทำนายเทียบกับค่าจริง (ซ้าย) และการกระจายของ residual บน test set (ขวา)




รูปที่ 2: ตัวอย่างภาพใบหน้าพร้อมอายุจริง (True) และอายุที่โมเดลทำนาย (Pred)

3. LAB 2: Classification — ทำนายเพศ (Gender Prediction)


ขั้นตอนของแล็บนี้ครอบคลุม 4 หัวข้อ:

- 1) Preparing Classification Data — โหลด pixel features + label เพศ แบ่ง train/test
- 2) Decision Boundary Visualization — ลดมิติด้วย PCA เหลือ 2 มิติ เพื่อวาด decision boundary ได้
- 3) Logistic Regression / Gender Prediction — pipeline StandardScaler → PCA(100) → LogisticRegression
- 4) Confusion Matrix — วิเคราะห์ผลการทำนายแยกตามคลาส


โมเดล	Test Accuracy
Decision-boundary model (PCA 2 มิติ)	0.547
Full Gender Classifier (PCA 100 มิติ)	0.743



รูปที่ 3: Decision boundary ของ Logistic Regression บนพื้นที่ 2 มิติ (PCA component 1-2)



รูปที่ 4: Confusion matrix ของโมเดลหลัก (PCA 100 มิติ) บน test set



รูปที่ 5: ตัวอย่างภาพพร้อมเพศจริงและเพศที่โมเดลทำนาย (สีเขียว = ถูก, สีแดง = ผิด)

4. LAB 3: Model Comparison

4.1 Simple vs Multiple Linear Regression

การเพิ่มจำนวน feature จาก 1 (ความสว่างเฉลี่ย) เป็น 1,024 (pixel ดิบทั้งหมด) ทำให้ R^2 เพิ่มขึ้นจาก 0.012 เป็น 0.450 อย่างชัดเจน แสดงว่าความสว่างเฉลี่ยเพียงอย่างเดียวแทบไม่มี ความสัมพันธ์เชิงเส้นกับอายุ ในขณะที่ pattern เชิงพื้นที่ของใบหน้า (ซึ่งอยู่ใน pixel ทั้งหมด) มีข้อมูลที่เป็นประโยชน์มากกว่ามาก

4.2 Training vs Testing Performance

โมเดล	Train MAE	Test MAE	ส่วนต่าง (Gap)	สรุป
Simple Linear Regression	19.83	19.82	-0.01	generalize ปกติ
Multiple Linear Regression	9.27	13.78	+4.50	overfitting
Age Pipeline (PCA+Ridge)	13.15	13.39	+0.24	generalize ปกติ

Multiple Linear Regression บน pixel ดิบ 1,024 ค่า มีช่องว่างระหว่าง train และ test มากที่สุด (overfitting) เพราะจำนวน feature ใกล้เคียงกับจำนวนตัวอย่างเทรน และ feature (pixel ข้างเคียงกัน) มีความสัมพันธ์กันสูงมาก ส่วน pipeline ที่ผ่าน PCA และใช้ Ridge (มี regularization) มีช่องว่างน้อยที่สุด แสดงถึงการ generalize ที่ดีกว่า แม้ค่า MAE บน train set จะสูงกว่าเล็กน้อยก็ตาม

4.3 Regression vs Classification

Regression (ทำนายอายุ) มี target เป็นค่าต่อเนื่อง จึงประเมินด้วย MAE / RMSE / R^2 ในขณะที่ Classification (ทำนายเพศ) มี target เป็นค่าจัดกลุ่ม (Male/Female) จึงประเมินด้วย Accuracy / Precision / Recall / F1 และ Confusion Matrix ทั้งสองงานใช้ pipeline โครงสร้างเดียวกัน (StandardScaler → PCA) ต่างกันแค่ estimator สุดท้าย (Ridge สำหรับ regression, LogisticRegression สำหรับ classification) ซึ่งสะท้อนว่าประเภทของ target เป็นตัวกำหนด การเลือกโมเดลและ metric ที่ใช้วัดผล

4.4 สรุปผลการทำงานของโมเดล (Model Performance Metrics)

งาน (Task)	โมเดลที่ดีที่สุด	ผลลัพธ์บน Test set
Age Prediction (Regression)	Scaler→PCA→Ridge	MAE = 13.39 ปี, R^2 = 0.489
Gender Prediction (Classification)	Scaler→PCA→LogisticRegression	Accuracy = 0.743

5. บทสรุป

การเพิ่มจำนวน feature ช่วยให้โมเดลเรียนรู้ pattern ได้ดีขึ้น แต่ก็เพิ่มความเสี่ยงที่จะ overfit หากไม่มีการควบคุมความซับซ้อนของโมเดล (เช่น regularization หรือการลดมิติด้วย PCA) จากผลการทดลองทั้งหมด pipeline แบบ StandardScaler → PCA → โมเดลเชิงเส้นที่มี regularization (Ridge / LogisticRegression) ให้ผลลัพธ์ที่สมดุลระหว่างความแม่นยำและการ generalize ได้ดีที่สุดในทั้งสองงาน (regression และ classification) บน dataset ภาพใบหน้านี้ อย่างไรก็ตาม โมเดลเชิงเส้นบน pixel ดิบยังมีข้อจำกัดด้าน accuracy เมื่อเทียบกับ state-of-the-art จริง (ซึ่งมักใช้ Convolutional Neural Network) เนื่องจากไม่ได้เรียนรู้ feature เชิงพื้นที่ (spatial feature) ของภาพโดยตรง