

รายงานโครงงาน ML-06-NN

การจำแนกประเภทสัตว์ด้วยอัลกอริทึม Nearest Neighbor (k-NN)
และการประยุกต์ใช้งาน

ชุดข้อมูล (Dataset)	Zoo Data Set — UCI Machine Learning Repository
อัลกอริทึม	k-Nearest Neighbors (k-NN) — scikit-learn
เป้าหมาย	จำแนกประเภทสัตว์ 7 คลาส จากลักษณะ 16 อย่าง
ผู้จัดทำ	TARo (จักรพัทธ์ ยอดระยับ)

1. บทนำ

โครงงานนี้จัดทำขึ้นเพื่อสาธิตหลักการทำงานของอัลกอริทึม **Nearest Neighbor (NN)** ซึ่งเป็นหนึ่งในอัลกอริทึมการเรียนรู้ของเครื่อง (Machine Learning) ที่มีแนวคิดพื้นฐานที่สุด นั่นคือการจำแนกข้อมูลใหม่โดยดูจาก "เพื่อนบ้าน"

ที่มีลักษณะใกล้เคียงกันที่สุดในชุดข้อมูลฝึกสอน โดยในโครงงานนี้ใช้ รูปแบบ **k-Nearest Neighbors (k-NN)** ซึ่งเป็นการขยายแนวคิดจาก Nearest Neighbor แบบพื้นฐาน ($k=1$) ให้พิจารณาเพื่อนบ้านที่ใกล้ที่สุด k ตัว แล้วใช้เสียงข้างมาก (majority vote) ในการตัดสินใจ

งานที่เลือกทำคือการจำแนกประเภทของสัตว์ (Animal Classification) ออกเป็น 7 กลุ่ม ได้แก่ สัตว์เลี้ยงลูกด้วยนม นก สัตว์เลื้อยคลาน ปลา สัตว์สะเทินน้ำสะเทินบก แมลง

และสัตว์ไม่มีกระดูกสันหลัง โดยอาศัยลักษณะทางกายภาพและพฤติกรรม 16 อย่าง เช่น มีขนหรือไม่ มีขนนกหรือไม่ ออกลูกเป็นไข่หรือไม่ มีนมเลี้ยงลูกหรือไม่ บินได้หรือไม่ อาศัยในน้ำหรือไม่ เป็นต้น

1.1 วัตถุประสงค์

- เพื่อศึกษาและสาธิตหลักการทำงานของอัลกอริทึม Nearest Neighbor / k-NN
- เพื่อสร้าง pipeline การเรียนรู้ของเครื่องแบบครบวงจร ตั้งแต่การโหลดข้อมูล การเตรียมข้อมูล การแบ่งชุดข้อมูล การเลือกค่าพารามิเตอร์ (k) ไปจนถึงการประเมินผล
- เพื่อสาธิตการประยุกต์ใช้งาน k-NN ในการเลือกค่า k ที่เหมาะสม (model selection) และความสำคัญของการปรับสเกลข้อมูล (feature scaling)

2. ชุดข้อมูล (Dataset)

ใช้ชุดข้อมูล **Zoo Data Set** จาก UCI Machine Learning Repository (<https://archive.ics.uci.edu/dataset/111/zoo>) ซึ่งประกอบด้วยข้อมูลสัตว์ 101 ชนิด แต่ละชนิดมีคุณลักษณะ (feature) จำนวน 16 อย่าง ส่วนใหญ่เป็นค่าไบนารี (0 หรือ 1) ยกเว้นคุณลักษณะ legs ที่เป็นจำนวนเต็มระบุจำนวนขา และป้ายกำกับ (label) คือ class_type ซึ่งมีค่าตั้งแต่ 1 ถึง 7 แทนประเภทของสัตว์ 7 กลุ่ม

คุณลักษณะทั้งหมด (16): hair, feathers, eggs, milk, airborne, aquatic, predator, toothed, backbone, breathes, venomous, fins, legs, tail, domestic, catsize

หมายเลขคลาส	ชื่อคลาส	จำนวนตัวอย่างในชุดข้อมูลทั้ง
1	สัตว์เลี้ยงลูกด้วยนม (Mammal)	41
2	นก (Bird)	20
3	สัตว์เลื้อยคลาน (Reptile)	5
4	ปลา (Fish)	13
5	สัตว์สะเทินน้ำสะเทินบก (Amphibian)	4
6	แมลง (Bug)	8
7	สัตว์ไม่มีกระดูกสันหลัง (Invertebrate)	10

จะเห็นว่าชุดข้อมูลนี้มีความไม่สมดุลระหว่างคลาส (class imbalance) ค่อนข้างมาก เช่น คลาส Mammal มีตัวอย่างมากถึง 41 ตัว ในขณะที่คลาส Amphibian มีเพียง 4 ตัว จึงต้องใช้การแบ่งข้อมูลแบบ stratified เพื่อให้ทุกคลาสปรากฏอยู่ในชุด train/validation/test อย่างเหมาะสม

3. ขั้นตอนการดำเนินงาน (Methodology)

3.1 การเตรียมข้อมูล (Data Loading & Preprocessing)

โหลดข้อมูลจาก dataset.csv ตรวจสอบและข้ามแถวที่มีค่าว่างหรือป้ายกำกับผิดช่วง จากนั้นแยกคุณลักษณะทั้ง 16 คอลัมน์ออกจากป้ายกำกับ และทำการ **ปรับสเกลข้อมูล (Standardization)** ด้วย StandardScaler โดย fit บนชุด training เท่านั้นแล้วนำไป transform ชุด validation และ test ขั้นตอนนี้สำคัญมาก สำหรับ k-NN เนื่องจากอัลกอริทึมนี้ใช้ระยะทางแบบ Euclidean ในการหาความใกล้เคียง หากไม่ปรับสเกล คุณลักษณะที่มีค่าตัวเลขสูง เช่น legs (0-8) จะมีอิทธิพลต่อระยะทาง มากกว่าคุณลักษณะไบนารี (0/1) อย่างไม่เป็นธรรม

3.2 การแบ่งชุดข้อมูล (Data Splitting)

แบ่งข้อมูลทั้งหมด 101 ตัวอย่างแบบ stratified ออกเป็น 3 ส่วน คือ ชุดฝึกสอน (train) 60 ตัวอย่าง (~60%), ชุดตรวจสอบ (validation) 20 ตัวอย่าง (~20%), และชุดทดสอบ (test) 21 ตัวอย่าง (~20%) โดยกำหนด random_state=42 เพื่อให้ผลลัพธ์สามารถทำซ้ำได้

3.3 การสร้างโมเดลและเลือกค่า k (Model Selection)

สร้างโมเดล KNeighborsClassifier จาก scikit-learn โดยใช้ระยะทางแบบ Euclidean (metric='minkowski', p=2) และน้ำหนักแบบเท่ากันทุกเพื่อนบ้าน (weights='uniform') ทดลองค่า k ตั้งแต่ 1 ถึง 15 แล้ววัดค่าความแม่นยำ (accuracy) บนชุด train และ validation ของแต่ละค่า k เพื่อเลือกค่า k ที่ให้ผลลัพธ์บน validation ดีที่สุด แล้วจึงนำ train และ validation มารวมกันเพื่อฝึกโมเดลสุดท้ายด้วยค่า k ที่เลือก

k	Train accuracy	Validation accuracy
1	1.00	0.85
2	0.95	0.85
3	0.95	0.90
4	0.90	0.95
5	0.93	0.95
6	0.85	0.90
7	0.80	0.90
8	0.83	0.95
9	0.82	0.95
10	0.82	0.95
11	0.85	0.95
12	0.85	0.95


k	Train accuracy	Validation accuracy
13	0.85	0.90
14	0.85	0.90
15	0.85	0.90

หมายถึงค่า k ที่เลือกใช้เป็นโมเดลสุดท้าย ($k = 4$)

4. ผลการทดลอง (Results)

4.1 กราฟความแม่นยำเทียบกับค่า k

จากกราฟด้านล่าง จะเห็นรูปแบบคลาสสิกของ k-NN คือเมื่อ k มีค่าน้อย (k=1) โมเดลจะ **overfit** กับข้อมูล training (train accuracy = 100%) แต่ทำงานได้ไม่ดี บนข้อมูลใหม่ (validation accuracy ต่ำกว่า) เมื่อ k เพิ่มขึ้นจนถึงจุดหนึ่ง validation accuracy จะสูงสุดที่ k = 4 หลังจากนั้นเมื่อ k มากเกินไป โมเดลจะ **underfit** เนื่องจากพิจารณาเพื่อนบ้านที่ไกลเกินไป ทำให้ขอบเขตการตัดสินใจ หยิบเกินไป




ภาพที่ 1: Accuracy เทียบกับค่า k บนชุด train และ validation

4.2 ผลการประเมินบนชุดทดสอบ (Test Set)

เมื่อนำโมเดลที่ k = 4 ไปทดสอบกับชุดข้อมูล test ที่ไม่เคยเห็นมาก่อน (21 ตัวอย่าง) ได้ค่าความแม่นยำ (accuracy) เท่ากับ **100.00%**

คลาส	Precision	Recall	F1-score	จำนวนตัวอย่าง
สัตว์เลี้ยงลูกด้วยนม	1.00	1.00	1.00	8
นก	1.00	1.00	1.00	4
สัตว์เลื้อยคลาน	1.00	1.00	1.00	1
ปลา	1.00	1.00	1.00	3
สัตว์สะเทินน้ำสะเทินบก	1.00	1.00	1.00	1
แมลง	1.00	1.00	1.00	2
สัตว์ไม่มีกระดูกสันหลัง	1.00	1.00	1.00	2




ภาพที่ 2: Confusion Matrix บนชุดทดสอบ

4.3 ตัวอย่างการทำนาย (Sample Predictions)

ทดสอบโมเดลกับตัวอย่างสุ่ม 4 ตัวจากชุดทดสอบ เพื่อตรวจสอบผลลัพธ์แบบรายตัวอย่าง ผลลัพธ์เป็นดังนี้:

ลำดับตัวอย่าง (test index)	คลาสจริง	คลาสที่ทำนาย	ผลลัพธ์
10	สัตว์ไม่มีกระดูกสันหลัง	สัตว์ไม่มีกระดูกสันหลัง	ถูกต้อง
4	สัตว์เลี้ยงลูกด้วยนม	สัตว์เลี้ยงลูกด้วยนม	ถูกต้อง
12	สัตว์เลี้ยงลูกด้วยนม	สัตว์เลี้ยงลูกด้วยนม	ถูกต้อง
1	นก	นก	ถูกต้อง



ภาพที่ 3: ผลการทำนายตัวอย่างสุ่ม 4 ตัวจากชุดทดสอบ

5. การประยุกต์ใช้งาน Nearest Neighbor

นอกเหนือจากการจำแนกประเภทสัตว์แล้ว โครงการนี้ยังสาธิตแนวทางการประยุกต์ใช้งาน อัลกอริทึม Nearest Neighbor ที่สำคัญ 2 ประการ ได้แก่

5.1 การเลือกค่า k ที่เหมาะสม (Hyperparameter / Model Selection)

แทนที่จะกำหนดค่า k แบบตายตัว โครงการนี้ค้นหาค่า k ที่เหมาะสมที่สุดโดยอาศัย validation set ซึ่งเป็นแนวทางมาตรฐานในการนำ k-NN ไปใช้งานจริง เนื่องจากค่า k ที่เล็กเกินไปทำให้โมเดลไวต่อ noise (overfitting) ในขณะที่ค่า k ที่ใหญ่เกินไปทำให้โมเดลหยาบเกินไปจนมองข้ามรายละเอียดสำคัญ (underfitting) การหาจุดสมดุลระหว่างสองขั้วนี้คือหัวใจของการนำ k-NN ไปประยุกต์ใช้ในงานจริง

5.2 ความสำคัญของการปรับสเกลข้อมูล (Feature Scaling)

เนื่องจาก k-NN เป็นอัลกอริทึมที่อาศัยระยะทาง (distance-based algorithm) โดยตรง การปรับสเกลคุณลักษณะให้อยู่ในช่วงใกล้เคียงกันก่อนคำนวณระยะทางจึงเป็น ขั้นตอนที่ขาดไม่ได้ โครงการนี้ใช้ StandardScaler ปรับให้ทุกคุณลักษณะมีค่าเฉลี่ย เป็น 0 และส่วนเบี่ยงเบนมาตรฐานเป็น 1 ซึ่งเป็นแนวทางที่นำไปใช้ได้กับงาน k-NN ประเภทอื่น เช่น

ระบบแนะนำสินค้า (recommendation system) หรือการค้นหภาพที่ คล้ายกัน (image similarity search) ที่ล้วนอาศัยหลักการวัดระยะทางเช่นเดียวกัน

6. สรุปผล

โมเดล k-Nearest Neighbors ที่พัฒนาขึ้นสามารถจำแนกประเภทสัตว์จากชุดข้อมูล Zoo ได้อย่างแม่นยำ โดยค่า k ที่เหมาะสมที่สุดที่พบคือ $k = 4$ ซึ่งให้ผล validation accuracy สูงสุดในบรรดาค่า k ที่ทดลอง ($k = 1$ ถึง 15) และเมื่อนำไป ทดสอบกับชุดข้อมูล test ที่ไม่เคยเห็นมาก่อน ได้ค่าความแม่นยำ 100.00% แสดงให้เห็นว่าคุณลักษณะทั้ง 16 อย่างในชุดข้อมูลนี้ มีความสัมพันธ์กับประเภทของสัตว์อย่างชัดเจน และ Nearest Neighbor เป็นอัลกอริทึม ที่เหมาะสมสำหรับปัญหาลักษณะนี้ ทั้งนี้ ควรระมัดระวังเรื่องขนาดชุดข้อมูลที่มีจำกัด (101 ตัวอย่าง) และความไม่สมดุลระหว่างคลาส ซึ่งอาจทำให้ผลลัพธ์ที่ได้ดูดีเกินจริง เมื่อเทียบกับการนำไปใช้งานกับชุดข้อมูลขนาดใหญ่ในโลกจริง

อ้างอิง (References)

Zoo Data Set, UCI Machine Learning Repository:
<https://archive.ics.uci.edu/dataset/111/zoo>

scikit-learn documentation - KNeighborsClassifier: <https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html>