

รายงานโครงงาน ML-06-NN

การจำแนกประเภทสัตว์ด้วยอัลกอริทึม Nearest Neighbor (NN)
และการประยุกต์ใช้งาน

ชุดข้อมูล (Dataset)	Zoo Data Set — UCI Machine Learning Repository
อัลกอริทึม	Nearest Neighbor (1-NN, n_neighbors=1) — scikit-learn
เป้าหมาย	จำแนกประเภทสัตว์ 7 คลาส จากลักษณะ 16 อย่าง
ผู้จัดทำ	TARo (จักรพัทธ์ ยอดระยับ)

1. บทนำ

โครงงานนี้จัดทำขึ้นเพื่อสาธิตหลักการทำงานของอัลกอริทึม **Nearest Neighbor (NN)** ในรูปแบบพื้นฐานที่สุด ซึ่งเป็นหนึ่งในอัลกอริทึม การเรียนรู้ของเครื่อง (Machine Learning) ที่มีแนวคิดง่ายที่สุด นั่นคือการจำแนก ข้อมูลใหม่โดยดูจาก "เพื่อนบ้านที่ใกล้ที่สุดเพียงตัวเดียว" ในชุดข้อมูลฝึกสอน (1-Nearest Neighbor หรือ 1-NN) แล้วนำป้ายกำกับของเพื่อนบ้านตัวนั้นมาใช้เป็นคำ ทำนายโดยตรง ต่างจาก k-Nearest Neighbors (k-NN) ที่พิจารณาเพื่อนบ้านหลายตัวแล้ว ใช้เสียงข้างมากตัดสิน —

โครงงานนี้ตั้งใจศึกษา Nearest Neighbor แบบดั้งเดิม ($k=1$) โดยเฉพาะ เพื่อให้เห็นกลไกการทำงานที่ตรงไปตรงมาที่สุดของอัลกอริทึมตระกูลนี้

งานที่เลือกทำคือการจำแนกประเภทของสัตว์ (Animal Classification) ออกเป็น 7 กลุ่ม ได้แก่ สัตว์เลี้ยงลูกด้วยนม นก สัตว์เลื้อยคลาน ปลา สัตว์สะเทินน้ำสะเทินบก แมลง และสัตว์ไม่มีกระดูกสันหลัง โดยอาศัยลักษณะทางกายภาพและพฤติกรรม 16 อย่าง เช่น มีขนหรือไม่ มีขนนกหรือไม่ ออกลูกเป็นไข่หรือไม่ มีนมเลี้ยงลูกหรือไม่ บินได้หรือไม่ อาศัยในน้ำหรือไม่ เป็นต้น

1.1 วัตถุประสงค์

- เพื่อศึกษาและสาธิตหลักการทำงานของอัลกอริทึม Nearest Neighbor (1-NN)
- เพื่อสร้าง pipeline การเรียนรู้ของเครื่องแบบครบวงจร ตั้งแต่การโหลดข้อมูล การเตรียมข้อมูล การแบ่งชุดข้อมูล การเทรนโมเดล ไปจนถึงการประเมินผล
- เพื่อสาธิตการประยุกต์ใช้งาน NN ด้านการย้อนรอยคำตอบ (traceability) และการใช้ระยะห่างเป็นตัวชี้วัดความมั่นใจ รวมถึงความสำคัญของการปรับสเกลข้อมูล (feature scaling)

2. ชุดข้อมูล (Dataset)

ใช้ชุดข้อมูล **Zoo Data Set** จาก UCI Machine Learning Repository (<https://archive.ics.uci.edu/dataset/111/zoo>) ซึ่งประกอบด้วยข้อมูลสัตว์ 101 ชนิด แต่ละชนิดมีคุณลักษณะ (feature) จำนวน 16 อย่าง ส่วนใหญ่เป็นค่าไบนารี (0 หรือ 1) ยกเว้นคุณลักษณะ legs ที่เป็นจำนวนเต็มระบุจำนวนขา และป้ายกำกับ (label) คือ class_type ซึ่งมีค่าตั้งแต่ 1 ถึง 7 แทนประเภทของสัตว์ 7 กลุ่ม

คุณลักษณะทั้งหมด (16): hair, feathers, eggs, milk, airborne, aquatic, predator, toothed, backbone, breathes, venomous, fins, legs, tail, domestic, catsize

หมายเลขคลาส	ชื่อคลาส	จำนวนตัวอย่างในชุดข้อมูลทั้ง
1	สัตว์เลี้ยงลูกด้วยนม (Mammal)	41
2	นก (Bird)	20
3	สัตว์เลื้อยคลาน (Reptile)	5
4	ปลา (Fish)	13
5	สัตว์สะเทินน้ำสะเทินบก (Amphibian)	4

6	แมลง (Bug)	8
7	สัตว์ไม่มีกระดูกสันหลัง (Invertebrate)	10

จะเห็นว่าชุดข้อมูลนี้มีความไม่สมดุลระหว่างคลาส (class imbalance) ค่อนข้างมาก เช่น คลาส Mammal มีตัวอย่างมากถึง 41 ตัว ในขณะที่คลาส Amphibian มีเพียง 4 ตัว จึงต้องใช้การแบ่งข้อมูลแบบ stratified เพื่อให้ทุกคลาสปรากฏอยู่ในชุด train/validation/test อย่างเหมาะสม

3. ขั้นตอนการดำเนินงาน (Methodology)

3.1 การเตรียมข้อมูล (Data Loading & Preprocessing)

โหลดข้อมูลจาก dataset.csv ตรวจสอบและข้ามแถวที่มีค่าว่างหรือป้ายกำกับผิดช่วง จากนั้นแยกคุณลักษณะทั้ง 16 คอลัมน์ออกจากป้ายกำกับ และทำการ **ปรับสเกลข้อมูล (Standardization)** ด้วย StandardScaler โดย fit บนชุด training เท่านั้นแล้วนำไป transform ชุด validation และ test ขั้นตอนนี้สำคัญมาก สำหรับ Nearest Neighbor เนื่องจากอัลกอริทึมนี้ใช้ระยะทางแบบ Euclidean ในการหา ความใกล้เคียง หากไม่ปรับสเกล คุณลักษณะที่มีค่าตัวเลขสูง เช่น legs (0-8) จะมี อิทธิพลต่อระยะทางมากกว่าคุณลักษณะไบนารี (0/1) อย่างไม่เป็นธรรม

3.2 การแบ่งชุดข้อมูล (Data Splitting)

แบ่งข้อมูลทั้งหมด 101 ตัวอย่างแบบ stratified ออกเป็น 3 ส่วน คือ ชุดฝึกสอน (train) 60 ตัวอย่าง (~60%), ชุดตรวจสอบ (validation) 20 ตัวอย่าง (~20%), และชุดทดสอบ (test) 21 ตัวอย่าง (~20%) โดยกำหนด random_state=42 เพื่อให้ผลลัพธ์ สามารถทำซ้ำได้ ชื่อสัตว์แต่ละตัวถูกแบ่งไปพร้อมกับข้อมูลตัวเลขด้วย เพื่อให้สามารถ ย้อนดูภายหลังได้ว่าคำทำนายแต่ละครั้งจับคู่กับสัตว์ตัวใดในชุดฝึกสอน

3.3 การสร้างโมเดล Nearest Neighbor

สร้างโมเดล **KNeighborsClassifier(n_neighbors=1)** จาก scikit-learn โดยใช้ ระยะทางแบบ Euclidean (metric='minkowski', p=2) เนื่องจาก n_neighbors=1 โมเดลจะพิจารณาเพื่อนบ้านที่ใกล้ที่สุดเพียงตัวเดียวเท่านั้น และใช้ป้ายกำกับของ เพื่อนบ้านตัวนั้นเป็นคำทำนายโดยตรง (ไม่มีการโหวตเสียงข้างมากแบบ k-NN และไม่มี พารามิเตอร์ k ให้ค้นหาหรือปรับแต่ง) จึงฝึกโมเดลด้วยข้อมูล train และ validation รวมกันในขั้นตอนเดียว เพื่อให้โมเดลมีตัวอย่างอ้างอิงมากที่สุดเท่าที่จะเป็นไปได้ โดยยังคงกันชุด test ไว้สำหรับวัดผลครั้งสุดท้ายเท่านั้น


4. ผลการทดลอง (Results)

4.1 ระยะห่างไปยัง Nearest Neighbor ของแต่ละตัวอย่างทดสอบ

เนื่องจากโมเดลนี้เป็น Nearest Neighbor แบบ $k=1$ จึงไม่มีค่า k ให้ปรับหรือกราฟ accuracy-เทียบกับ- k แบบ k -NN ทั่วไป แต่สิ่งที่น่าสนใจกว่าคือ

ระยะห่างไปยังเพื่อนบ้านที่ใกล้ที่สุด ของแต่ละตัวอย่างทดสอบ ซึ่งสะท้อนว่า ตัวอย่างนั้น "คล้าย" กับสิ่งที่โมเดลเคยเห็นมากจนมากแค่ไหน จากกราฟด้านล่าง

จะเห็นว่าสัตว์หลายตัวมีระยะห่าง ≈ 0 (เช่น lynx จับคู่กับ polecat, goat จับคู่กับ reindeer) เพราะมีค่าฟีเจอร์ไบนารีทั้ง 16 ค่าตรงกันทุกตัวพอดี ซึ่งเป็นลักษณะที่พบ ได้อยู่ของชุดข้อมูล Zoo ที่ใช้ฟีเจอร์แบบหยาบ (coarse binary features) ส่วน ตัวอย่างที่มีระยะห่างมากกว่า (เช่น octopus) หมายความว่าไม่มีสัตว์ตัวใดในชุดฝึกสอน ที่เหมือนกันปะ แต่โมเดลก็ยังทำนายถูกเพราะยังใกล้เคียงกับกลุ่มเดียวกันมากที่สุด




ภาพที่ 1: ระยะห่างไปยัง Nearest Neighbor ของแต่ละตัวอย่างทดสอบ (เขียว = ทำนายถูก)

4.2 ผลการประเมินบนชุดทดสอบ (Test Set)

เมื่อนำโมเดล Nearest Neighbor ไปทดสอบกับชุดข้อมูล test ที่ไม่เคยเห็นมาก่อน (21 ตัวอย่าง) ได้ค่าความแม่นยำ (accuracy) เท่ากับ **100.00%**

คลาส	Precision	Recall	F1-score	จำนวนตัวอย่าง
สัตว์เลี้ยงลูกด้วยนม	1.00	1.00	1.00	8
นก	1.00	1.00	1.00	4
สัตว์เลื้อยคลาน	1.00	1.00	1.00	1
ปลา	1.00	1.00	1.00	3
สัตว์สะเทินน้ำสะเทินบก	1.00	1.00	1.00	1
แมลง	1.00	1.00	1.00	2

สัตว์ไม่มีกระดูกสันหลัง	1.00	1.00	1.00	2
-------------------------	------	------	------	---




ภาพที่ 2: Confusion Matrix บนชุดทดสอบ

4.3 ตัวอย่างการทำนายพร้อมย้อนรอยเพื่อนบ้าน (Sample Predictions)

ทดสอบโมเดลกับตัวอย่างสุ่ม 4 ตัวจากชุดทดสอบ เพื่อตรวจสอบผลลัพธ์แบบรายตัวอย่าง พร้อมย้อนดูว่าโมเดลจับคู่กับสัตว์ตัวใดในชุดฝึกสอน (nearest neighbor) และระยะทาง จริง ผลลัพธ์เป็นดังนี้:

สัตว์ (ทดสอบ)	คลาสจริง	คลาสที่ทำนาย	เพื่อนบ้านที่ใกล้ที่สุด	ระยะทาง
octopus	สัตว์ไม่มีกระดูกสันหลัง	สัตว์ไม่มีกระดูกสันหลัง	lobster	2.26
lynx	สัตว์เลี้ยงลูกด้วยนม	สัตว์เลี้ยงลูกด้วยนม	polecat	0.00
goat	สัตว์เลี้ยงลูกด้วยนม	สัตว์เลี้ยงลูกด้วยนม	reindeer	0.00
lark	นก	นก	wren	0.00



ภาพที่ 3: ผลการทำนายตัวอย่างสุ่ม 4 ตัวจากชุดทดสอบ พร้อมเพื่อนบ้านที่ใกล้ที่สุดและระยะทาง

5. การประยุกต์ใช้งาน Nearest Neighbor

นอกเหนือจากการจำแนกประเภทสัตว์แล้ว โครงงานนี้ยังสาธิตแนวคิดการประยุกต์ใช้งาน Nearest Neighbor ที่สำคัญ 3 ประการ ได้แก่

5.1 การย้อนรอยคำตอบ (Traceability / Interpretability)

เพราะ Nearest Neighbor ตัดสินใจจากเพื่อนบ้านเพียงตัวเดียว ทุกคำทำนายจึงสามารถอธิบายได้ตรงไปตรงมาว่า "ทำนายแบบนี้เพราะคล้ายกับสัตว์ตัวนี้ในชุดฝึกสอนมากที่สุด" ดังตัวอย่างในตารางหัวข้อ 4.3 ที่ระบุชัดเจนว่า lark ถูกจับคู่กับ wren เป็นต้น ความสามารถในการย้อนรอยเช่นนี้เป็นจุดเด่นที่โมเดลแบบ black-box อื่น (เช่น Neural Network) ให้ได้ยากกว่ามาก

5.2 ระยะทางเป็นตัวชี้วัดความมั่นใจ (Distance as Confidence)

ถ้าตัวอย่างใหม่มีระยะทางไปยัง nearest neighbor มาก แปลว่าไม่คล้ายกับสิ่งที่เคยเห็นมาก่อนเลย ซึ่งนำไปใช้เป็นสัญญาณเตือนความไม่มั่นใจของคำทำนาย หรือใช้ตรวจจับข้อมูลผิดปกติ (novelty / outlier detection) ได้ในงานจริง เช่น ถ้าพบสัตว์ชนิดใหม่

ที่มีระยะห่างไปยังเพื่อนบ้านที่ใกล้ที่สุดสูงผิดปกติ ระบบสามารถตั้งค่าให้แจ้งเตือน แทนที่จะพินิจคำตอบโดยไม่มีการเตือนใด ๆ

5.3 ความสำคัญของการปรับสเกลข้อมูล (Feature Scaling)

เนื่องจาก Nearest Neighbor เป็นอัลกอริทึมที่อาศัยระยะห่าง (distance-based algorithm) โดยตรง การปรับสเกลคุณลักษณะให้อยู่ในช่วงใกล้เคียงกันก่อนคำนวณระยะห่างจึงเป็นขั้นตอนที่ขาดไม่ได้ โครงการนี้ใช้ StandardScaler ปรับให้ทุกคุณลักษณะมีค่าเฉลี่ยเป็น 0 และส่วนเบี่ยงเบนมาตรฐานเป็น 1 ซึ่งเป็นแนวทางที่นำไปใช้ได้กับงาน NN ประเภทอื่น เช่น ระบบแนะนำสินค้า (recommendation system) หรือการค้นหาภาพที่คล้ายกัน (image similarity search) ที่ล้วนอาศัยหลักการวัดระยะห่าง เช่นเดียวกัน

6. สรุปผล

โมเดล Nearest Neighbor แบบพื้นฐาน (1-NN) ที่พัฒนาขึ้นสามารถจำแนกประเภทสัตว์จากชุดข้อมูล Zoo ได้อย่างแม่นยำ โดยเมื่อนำไปทดสอบกับชุดข้อมูล test ที่ไม่เคยเห็นมาก่อน ได้ค่าความแม่นยำ 100.00% แสดงให้เห็นว่าคุณลักษณะ ทั้ง 16 อย่างในชุดข้อมูลนี้มีความสัมพันธ์กับประเภทของสัตว์อย่างชัดเจน แม้จะใช้เพื่อนบ้านเพียงตัวเดียวในการตัดสินใจก็ตาม จุดเด่นสำคัญของแนวทางนี้คือความง่ายในการอธิบายผลลัพธ์ (ย้อนรอยได้ว่าจับคู่กับสัตว์ตัวใด) และการใช้ระยะห่างเป็นตัวชี้วัด ความมั่นใจทั้งนี้ ควรระมัดระวังเรื่องขนาดชุดข้อมูลที่มีจำกัด (101 ตัวอย่าง) ความไม่สมดุลระหว่างคลาส และข้อจำกัดของ 1-NN ที่ไวต่อสัญญาณรบกวน (noise) มากกว่า k-NN ที่ใช้เสียงข้างมากจากหลายเพื่อนบ้านช่วยลดผลกระทบของตัวอย่างผิดปกติเพียงตัวเดียว ซึ่งอาจมีนัยสำคัญมากขึ้นเมื่อนำไปใช้งานกับชุดข้อมูลขนาดใหญ่และซับซ้อนกว่านี้ ในโลกจริง

อ้างอิง (References)

Zoo Data Set, UCI Machine Learning Repository:

<https://archive.ics.uci.edu/dataset/111/zoo>

scikit-learn documentation - KNeighborsClassifier: <https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html>