

รายงานโครงงาน ML-07-CNN

การจำแนกตำแหน่งโปรตีนในเซลล์ยีสต์ด้วยโครงข่ายประสาทเทียมแบบคอนโวลูชัน 1 มิติ (1D Convolutional Neural Network)

ชุดข้อมูล (Dataset)	Yeast Dataset (UCI Machine Learning Repository)
จำนวนตัวอย่าง	1,484 แถว (8 คุณสมบัติเชิงตัวเลข)
จำนวนคลาส	10 คลาส (CYT, ERL, EXC, ME1, ME2, ME3, MIT, NUC, POX, VAC)
โมเดลที่ใช้	1D Convolutional Neural Network (TensorFlow / Keras)
ความแม่นยำบนชุดทดสอบ	59.63%

1. บทนำ

โครงงานนี้มีวัตถุประสงค์เพื่อสร้างโครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network: CNN) สำหรับจำแนกตำแหน่งการอยู่อาศัยของโปรตีนภายในเซลล์ยีสต์ (protein subcellular localization) จากค่าคุณลักษณะทางชีวเคมี 8 ค่าที่คำนวณได้จากลำดับ กรดอะมิโนของโปรตีนแต่ละชนิด

โครงร่างของงานที่ได้รับมอบหมาย (ML-07-CNN template) ถูกออกแบบมาสำหรับข้อมูลรูปภาพ (เช่น การจำแนกภาพแมวและสุนัขในโฟลเดอร์ PetImages) อย่างไรก็ตาม ชุดข้อมูลที่ใช้จริงในโครงงานนี้ คือ yeast.csv ซึ่งเป็น ข้อมูลตาราง (tabular data) ไม่ใช่รูปภาพ ผู้จัดทำจึงปรับสถาปัตยกรรม จาก 2D-CNN (ที่ออกแบบมาสำหรับข้อมูลภาพ) เป็น 1D-CNN ซึ่งเหมาะสมกับข้อมูลที่อยู่ในรูปแบบ เวกเตอร์ตัวเลขต่อเนื่อง โดยยังคงขั้นตอนการทำงานแบบเดียวกับ CNN สำหรับภาพ ได้แก่ การโหลดข้อมูล การเตรียมข้อมูล การแบ่งชุดข้อมูล การฝึกโมเดล และการประเมินผล

2. ชุดข้อมูล (Dataset)

ชุดข้อมูล Yeast มาจาก UCI Machine Learning Repository ประกอบด้วยข้อมูลโปรตีน 1,484 ตัวอย่าง แต่ละตัวอย่างมีคุณลักษณะเชิงตัวเลข 8 ค่า (ค่าทั้งหมดอยู่ในช่วง 0-1) และป้ายกำกับ (label) ระบุตำแหน่งที่โปรตีนนั้นอยู่ในเซลล์ ดังตารางต่อไปนี้:

คุณลักษณะ	ความหมายโดยสังเขป
mcg	คะแนนจากวิธี McGeoch สำหรับสัญญาณการส่งออกโปรตีน (signal sequence)
gvh	คะแนนจากวิธี von Heijne สำหรับสัญญาณเดียวกัน
alm	คะแนนจากโปรแกรม ALOM ที่ทำนายบริเวณเยื่อหุ้มเซลล์ (membrane spanning region)
mit	คะแนนจากการวิเคราะห์ลำดับสัญญาณไมโทคอนเดรีย (mitochondrial signal)
erl	ค่าบ่งชี้การมีลำดับสัญญาณ HDEL (endoplasmic reticulum)
pox	คะแนนบ่งชี้โมทีฟ peroxisomal targeting signal
vac	คะแนนจากการวิเคราะห์โปรตีนในแวคิวโอล (vacuolar)
nuc	คะแนนบ่งชี้สัญญาณนำเข้านิวเคลียส (nuclear localization signal)

ป้ายกำกับ (class) มีทั้งหมด 10 คลาส ได้แก่ CYT (cytosolic/cytoskeletal), NUC (nuclear), MIT (mitochondrial), ME1/ME2/ME3 (membrane protein แบบต่าง ๆ), EXC (extracellular), VAC (vacuolar), POX (peroxisomal) และ ERL (endoplasmic reticulum lumen) ทั้งนี้ การกระจายตัวของแต่ละคลาสไม่สมดุลกันอย่างมาก โดยคลาส CYT มีจำนวนมากที่สุด (463 ตัวอย่าง) ในขณะที่คลาส ERL มีเพียง 5 ตัวอย่างเท่านั้น ซึ่งเป็นปัจจัยสำคัญที่ทำให้การจำแนกคลาสส่วนน้อยทำได้ยาก

3. ระเบียบวิธี (Methodology)

3.1 การเตรียมข้อมูล (Data Loading & Preprocessing)

- 1) data_loader.py — โหลดข้อมูลจาก dataset.csv ตรวจสอบและตัดแถวที่มีค่าว่างหรือค่าที่ไม่ใช่ตัวเลข (คล้ายกับการข้ามไฟล์ภาพที่เสียหายในปัญหาแบบภาพ) รวมถึงลบแถวที่ซ้ำกัน

2) preprocessing.py — ปรับสเกลคุณลักษณะทั้ง 8 ค่าด้วย StandardScaler (ให้ค่าเฉลี่ย = 0 ส่วนเบี่ยงเบนมาตรฐาน = 1) จากนั้นเข้ารหัสป้ายกำกับข้อความเป็นตัวเลขด้วย LabelEncoder และปรับรูปร่าง เวกเตอร์คุณลักษณะจาก (8,) เป็น (8, 1) เพื่อให้สอดคล้องกับอินพุตที่ Conv1D ต้องการ (แกน channel)

3) split_data.py — แบ่งข้อมูลแบบ stratified (คงสัดส่วนคลาสในทุกชุด) เป็นชุดฝึก 70% ชุด validation 15% และชุดทดสอบ 15%

3.2 สถาปัตยกรรมโมเดล (Model Architecture)

โมเดลถูกสร้างด้วย TensorFlow/Keras ในไฟล์ cnn_model.py ประกอบด้วยชั้น Conv1D สองชั้นเพื่อเรียนรู้ความสัมพันธ์ระหว่างคุณลักษณะที่อยู่ใกล้กัน ตามด้วย Global Average Pooling และชั้น Dense สำหรับจำแนกคลาสสุดท้าย ดังนี้:

```
Input (8, 1)
-> Conv1D(32, kernel_size=3, activation='relu') + BatchNormalization
-> Conv1D(64, kernel_size=3, activation='relu') + BatchNormalization
-> GlobalAveragePooling1D
-> Dense(64, activation='relu') + Dropout(0.3)
-> Dense(10, activation='softmax')
```

การฝึกโมเดลใช้ Optimizer แบบ Adam (learning rate = 0.001) และฟังก์ชันสูญเสีย sparse categorical cross-entropy พร้อมเทคนิค Early Stopping ที่เฝ้าติดตามค่า validation loss (patience = 10 epoch) เพื่อป้องกันปัญหา overfitting

3.3 การประเมินผลและการทดสอบ

evaluate.py คำนวณความแม่นยำโดยรวม (accuracy), classification report (precision, recall, F1-score รายคลาส) และ confusion matrix บนชุดทดสอบ ส่วน test_cnn.py สุ่มตัวอย่าง 4 ตัวอย่าง จากชุดทดสอบมาทำนายและแสดงผลเปรียบเทียบระหว่างค่าจริงกับค่าที่โมเดลทำนาย


4. ผลการทดลอง (Results)

โมเดล 1D-CNN ทำความแม่นยำบนชุดทดสอบได้ 59.63%
ซึ่งใกล้เคียงกับผลลัพธ์ที่มีการรายงานในงานวิจัยที่ใช้ชุดข้อมูล Yeast นี้ (โดยทั่วไปอยู่ในช่วง 55-60%)
เนื่องจากชุดข้อมูลนี้มีลักษณะคลาสไม่สมดุลและขอบเขตของคลาสบางคู่กับซ้อนกันในเชิงคุณลักษณะ

4.1 ตารางผลการจำแนกรายคลาส (Classification Report)


Class	Precision	Recall	F1-score	Support
CYT	0.47	0.71	0.57	66
ERL	0.00	0.00	0.00	1
EXC	0.50	0.40	0.44	5
ME1	0.60	1.00	0.75	6
ME2	0.75	0.38	0.50	8
ME3	0.86	0.79	0.83	24
MIT	0.72	0.57	0.64	37
NUC	0.65	0.48	0.55	64
POX	0.50	0.33	0.40	3
VAC	0.00	0.00	0.00	4
accuracy			0.60	218

4.2 Confusion Matrix




รูปที่ 1: Confusion Matrix แสดงจำนวนตัวอย่างที่โมเดลทำนายถูก/ผิดในแต่ละคลาสบนชุดทดสอบ จะเห็นว่าคลาสที่มีตัวอย่างมาก (CYT, NUC, MIT) มีแนวโน้มถูกทำนายได้ดีกว่าคลาสที่มีตัวอย่างน้อย (ERL, VAC, POX) อย่างชัดเจน และคลาส CYT/NUC มีความสับสนกันเองค่อนข้างมาก เนื่องจากคุณลักษณะของโปรตีนสองกลุ่มนี้มีความใกล้เคียงกัน

4.3 กราฟการฝึกโมเดล (Training History)



รูปที่ 2: ค่า Loss และ Accuracy ของชุดฝึก (train) และชุด validation ตลอดการฝึกโมเดล แสดงให้เห็นว่าโมเดลลู่เข้า (converge) ได้ดีโดยไม่มีสัญญาณของ overfitting ที่รุนแรง เนื่องจากค่า validation loss ไม่ได้เพิ่มขึ้นสวนทางกับ training loss อย่างชัดเจน

4.4 ตัวอย่างการทำนาย (Prediction Sample)



รูปที่ 3: ผลการทดสอบโมเดลกับตัวอย่างที่สุ่มมา 4 ตัวอย่างจากชุดทดสอบ กราฟแท่งสีน้ำเงินหมายถึง ทำนายถูกต้อง ส่วนสีแดงหมายถึงทำนายผิด พร้อมแสดงค่าความมั่นใจ (confidence) ของโมเดลกำกับไว้ที่หัวข้อ แต่ละภาพ

5. สรุปและอภิปรายผล (Conclusion & Discussion)

โครงข่ายประสาทเทียมแบบ 1D-CNN สามารถเรียนรู้และจำแนกตำแหน่งของโปรตีนในเซลล์ยีสต์ได้ในระดับที่ใกล้เคียงกับผลงานวิจัยที่เผยแพร่ก่อนหน้านี้ โดยจุดแข็งของโมเดลอยู่ที่คลาสที่มีจำนวนตัวอย่างมากพอ เช่น ME1, ME3 และ MIT ในขณะที่คลาสที่มีตัวอย่างน้อยมาก เช่น ERL (5 ตัวอย่าง) และ VAC (30 ตัวอย่าง) โมเดลแทบไม่สามารถเรียนรู้รูปแบบได้ ซึ่งเป็นข้อจำกัดที่เกิดจากปัญหา class imbalance ของชุดข้อมูลเอง ไม่ใช่ข้อจำกัดของสถาปัตยกรรมโมเดล

แนวทางที่อาจช่วยปรับปรุงผลลัพธ์ในอนาคต ได้แก่ การทำ oversampling (เช่น SMOTE) สำหรับคลาสส่วนน้อย การปรับค่าถ่วงน้ำหนักของแต่ละคลาส (class weighting) ในฟังก์ชันสูญเสีย หรือการเพิ่มข้อมูลจากแหล่งอื่น เพื่อให้จำนวนตัวอย่างของแต่ละคลาสสมดุลกันมากขึ้น

โดยสรุป โครงงานนี้แสดงให้เห็นว่าแนวคิดของ CNN ซึ่งเดิมออกแบบมาสำหรับข้อมูลภาพ สามารถปรับใช้กับข้อมูลตาราง (tabular data) ได้ผ่านการนำ Conv1D โดยยังคงขั้นตอนหลักของ pipeline แบบเดียวกัน ได้แก่ การเตรียมข้อมูล การฝึกโมเดล และการประเมินผล